

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):
<https://www.youtube.com/watch?v=RoNQySNH7es>
- Link slides (dạng .pdf đặt trên Github của nhóm):
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Phạm Công Lập
- MSSV: 250202045



- Lớp: CS2205.JAN2026
- Tự đánh giá (điểm tổng kết môn): 9.5/10
- Số buổi vắng: 0
- Số câu hỏi QT cá nhân: 4
- Link Github:
<https://github.com/Clapboiz/CS2205.JAN2026>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

PHÁT HIỆN MALWARE THÍCH NGHI CONCEPT DRIFT SỬ DỤNG GRAPH NEURAL NETWORK VÀ DOMAIN ADAPTATION

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

ADAPTIVE MALWARE DETECTION UNDER CONCEPT DRIFT USING GRAPH NEURAL NETWORKS AND DOMAIN ADAPTATION

TÓM TẮT *(Tối đa 400 từ)*

Sự phát triển liên tục của malware hiện đại làm cho phân phối dữ liệu thay đổi theo thời gian, dẫn đến hiện tượng concept drift và làm suy giảm đáng kể hiệu năng của các hệ thống phát hiện malware truyền thống. Các mô hình được huấn luyện theo giả định phân phối dữ liệu tĩnh thường mất khả năng tổng quát hóa khi malware thay đổi loader, packer hoặc hành vi thực thi. Ngoài ra, trong môi trường thực tế, việc gán nhãn dữ liệu malware mới thường tốn nhiều thời gian và chi phí, khiến bài toán thích nghi với dữ liệu mới trở nên khó khăn hơn.

Đề tài tập trung nghiên cứu bài toán phát hiện malware Windows dạng PE trong điều kiện phân phối dữ liệu thay đổi theo thời gian và số lượng nhãn ở miền đích bị hạn chế. Nghiên cứu tập trung vào static malware analysis và không xử lý dynamic behavioral analysis nhằm đảm bảo tính khả thi về thời gian và tài nguyên tính toán. Nhóm đề xuất framework kết hợp Control Flow Graph (CFG), PalmTree embedding, Graph Neural Network và adversarial domain adaptation nhằm học các đặc trưng bất biến miền cho malware detection. Trong đó, CFG được sử dụng để biểu diễn cấu trúc thực thi của malware, PalmTree giúp trích xuất ngữ nghĩa lệnh assembly, còn Graph Isomorphism Network (GIN) đóng vai trò học biểu diễn đồ thị. Cơ chế adversarial domain adaptation được sử dụng để căn chỉnh phân phối giữa miền nguồn và miền đích nhằm giảm ảnh hưởng của concept drift.

Hệ thống được đánh giá trên các bộ dữ liệu Big-15, MalwareDrift và MB-24 với

nhiều kịch bản drift khác nhau như temporal drift, malware evolution và few-shot target adaptation. Nghiên cứu kỳ vọng phương pháp đề xuất có khả năng duy trì hiệu năng ổn định hơn so với các chiến lược cold-start và warm-start trong điều kiện dữ liệu nhãn hạn chế. Ngoài ra, nghiên cứu còn đánh giá khả năng giảm ảnh hưởng của obfuscation và khảo sát khả năng phát hiện malware chưa từng xuất hiện thông qua open-set domain adaptation.

Nghiên cứu kỳ vọng việc kết hợp graph representation và domain adaptation sẽ là hướng tiếp cận tiềm năng cho các hệ thống phát hiện malware thích nghi trong môi trường thực tế.

GIỚI THIỆU *(Tối đa 1 trang A4)*

Sự bùng nổ của các cuộc tấn công mạng trong những năm gần đây khiến malware trở thành một trong những mối đe dọa nghiêm trọng đối với hệ thống thông tin. Các họ malware hiện đại liên tục thay đổi cấu trúc, kỹ thuật obfuscation và hành vi thực thi nhằm vượt qua các hệ thống phát hiện truyền thống. Điều này làm cho phân phối dữ liệu malware thay đổi theo thời gian và dẫn đến hiện tượng concept drift [1].

Các phương pháp phát hiện malware truyền thống thường giả định dữ liệu huấn luyện và dữ liệu kiểm thử có cùng phân phối. Tuy nhiên, trong môi trường thực tế, malware mới thường khác biệt đáng kể so với dữ liệu đã được sử dụng để huấn luyện trước đó. Khi drift xảy ra, hiệu năng mô hình suy giảm đáng kể và cần được cập nhật liên tục [2]. Ngoài ra, nhiều phương pháp static malware detection hiện nay chưa xử lý hiệu quả bài toán lệch phân phối dữ liệu theo thời gian, trong khi việc gán nhãn malware mới thường tốn nhiều chi phí và phụ thuộc vào chuyên gia phân tích.

Nhiều nghiên cứu gần đây cho thấy graph representation và Graph Neural Network có khả năng biểu diễn hành vi malware hiệu quả hơn các phương pháp truyền thống [3][4]. Đồng thời, domain adaptation cho phép mô hình học các đặc trưng ổn định giữa nhiều miền dữ liệu khác nhau và giảm ảnh hưởng của lệch phân phối [5].

Từ các vấn đề trên, đề tài tập trung nghiên cứu framework phát hiện malware thích nghi concept drift bằng cách kết hợp Control Flow Graph, PalmTree embedding,

Graph Neural Network và adversarial domain adaptation. Nghiên cứu hướng tới xây dựng mô hình có khả năng duy trì hiệu năng phát hiện malware trong điều kiện dữ liệu nhãn hạn chế và phân phối dữ liệu thay đổi theo thời gian.

Các đóng góp chính của nghiên cứu bao gồm:

- Đề xuất framework phát hiện malware thích nghi concept drift dựa trên graph representation và adversarial domain adaptation.
- Khảo sát hiệu quả của domain adaptation trong điều kiện malware drift và label scarcity.
- Đánh giá khả năng chống obfuscation và khảo sát khả năng phát hiện malware chưa từng xuất hiện thông qua open-set domain adaptation.


Input của hệ thống là các tệp malware Windows dạng PE và mã assembly được disassembly từ malware. Output của hệ thống bao gồm nhãn phân loại malware, xác suất dự đoán của mô hình và khả năng cảnh báo các mẫu malware chưa từng xuất hiện thông qua open-set detection.

MỤC TIÊU (*Viết trong vòng 3 mục tiêu*)

- Khảo sát ảnh hưởng của concept drift đối với các mô hình phát hiện malware Windows trong môi trường thực tế.
- Xây dựng framework kết hợp CFG, PalmTree embedding và Graph Neural Network nhằm học đặc trưng malware ổn định theo thời gian.
- Đánh giá hiệu quả của adversarial domain adaptation trong điều kiện dữ liệu nhãn hạn chế, malware evolution và temporal distribution shift thông qua các chỉ số Accuracy, F1-score và mức cải thiện so với các mô hình không sử dụng domain adaptation.

NỘI DUNG VÀ PHƯƠNG PHÁP

Pipeline tổng quát của hệ thống được mô tả trong Hình 1.



Hình 1: Pipeline phát hiện malware thích nghi concept drift sử dụng Graph Neural Network và Domain Adaptation.

Nghiên cứu được triển khai theo các bước chính như sau:

1. Thu thập và tiền xử lý dữ liệu

Các bộ dữ liệu malware được sử dụng gồm Big-15, MalwareDrift và MB-24.

Malware được disassembly để thu được mã assembly và các thông tin phục vụ xây dựng Control Flow Graph. Dữ liệu được chia thành miền nguồn và miền đích theo các kịch bản temporal drift và malware evolution.

2. Xây dựng Control Flow Graph (CFG)

Mỗi malware được biểu diễn dưới dạng đồ thị luồng điều khiển nhằm mô tả cấu trúc thực thi của chương trình. Các basic block đóng vai trò node và luồng chuyển điều khiển đóng vai trò edge trong đồ thị.

3. Trích xuất đặc trưng bằng PalmTree

PalmTree được sử dụng để sinh embedding cho các lệnh assembly nhằm khai thác ngữ nghĩa của mã máy [6]. Các vector embedding sau đó được gán vào node của CFG để tạo biểu diễn đồ thị giàu thông tin hơn.

4. Học biểu diễn bằng Graph Neural Network

Nghiên cứu sử dụng Graph Isomorphism Network kết hợp Jumping Knowledge nhằm

học biểu diễn malware từ CFG [7][8]. Mô hình học các đặc trưng hành vi quan trọng và tạo embedding cho từng malware sample.

5. Adversarial Domain Adaptation

Một discriminator được sử dụng để phân biệt dữ liệu miền nguồn và miền đích.

Shared Generator được huấn luyện theo cơ chế đối nghịch nhằm học đặc trưng bất biến miền và giảm khoảng cách phân phối giữa các miền dữ liệu.

6. Đánh giá thực nghiệm

Hệ thống được đánh giá trên các kịch bản few-shot target adaptation, temporal malware drift, open-set domain adaptation và malware obfuscation. Mô hình được so sánh với các phương pháp static malware detection, warm-start và cold-start nhằm đánh giá khả năng thích nghi trong điều kiện phân phối dữ liệu thay đổi theo thời gian.

Các chỉ số đánh giá bao gồm Accuracy, F1-score và khả năng phát hiện malware chưa từng xuất hiện.

KẾT QUẢ MONG ĐỢI

- Xây dựng thành công pipeline phát hiện malware thích nghi concept drift dựa trên graph representation và domain adaptation.
- Mô hình được kỳ vọng cải thiện F1-score trong điều kiện few-shot target adaptation trên bộ dữ liệu Big-15.
- Giảm số lượng mẫu malware cần gán nhãn trong quá trình thích nghi miền đích so với các phương pháp warm-start truyền thống.
- Đánh giá mức suy giảm hiệu năng của mô hình theo thời gian và khả năng giảm ảnh hưởng của concept drift thông qua so sánh với các baseline truyền thống.
- Hướng tới giảm mức suy giảm hiệu năng phát hiện malware trong các kịch bản temporal drift, malware evolution và malware obfuscation khi phân phối dữ liệu thay đổi theo thời gian.
- Khảo sát khả năng phát hiện các họ malware chưa từng xuất hiện thông qua open-set domain adaptation.

- Đề xuất hướng tiếp cận khả thi cho các hệ thống SOC và malware analysis pipeline trong môi trường thực tế có phân phối dữ liệu thay đổi theo thời gian.

TÀI LIỆU THAM KHẢO (*Định dạng DBLP*)

- [1]. Adrian Shuai Li, Arun Iyengar, Ashish Kundu, Elisa Bertino:
Revisiting Concept Drift in Windows Malware Detection: Adaptation to Real Drifted Malware with Minimal Samples. NDSS 2025.
- [2]. Roberto Jordaney, Kumar Sharad, Santanu Kumar Dash, Zhi Wang, Davide Papini, Ilia Nouretdinov, Lorenzo Cavallaro:
Transcend: Detecting Concept Drift in Malware Classification Models. USENIX Security Symposium 2017.
- [3]. Jiaqi Yan, Guanhua Yan, Dong Jin:
Classifying Malware Represented as Control Flow Graphs using Deep Graph Convolutional Neural Network. DSN 2019: 52-63.
- [4]. Yun Gao, Hirokazu Hasegawa, Yukiko Yamaguchi, Hajime Shimada:
Malware Detection by Control-Flow Graph Level Representation Learning With Graph Isomorphism Network. IEEE Access 2022: 111830-111841.
- [5]. Yaroslav Ganin, Victor Lempitsky:
Unsupervised Domain Adaptation by Backpropagation. ICML 2015: 1180-1189.
- [6]. Xuezixiang Li et al.:
PalmTree: Learning an Assembly Language Model for Instruction Embedding. CCS 2021.
- [7]. Keyulu Xu, Weihua Hu, Jure Leskovec, Stefanie Jegelka:
How Powerful are Graph Neural Networks? ICLR 2019.
- [8]. Keyulu Xu, Chengtao Li, Yonglong Tian, Tomohiro Sonobe, Ken-ichi Kawarabayashi, Stefanie Jegelka:
Representation Learning on Graphs with Jumping Knowledge Networks. ICML 2018: 5453-5462.